한국어 임상 데이터 처리를 위한 Domain-Adaptive Pretraining과 From-Scratch Pretraining 기반 BERT 모델의 성능 비교

BERT Models for Korean Clinical NLP: Comparing Domain-Adaptive Pretraining and From-Scratch Pretraining Approaches

Young Jun Park*, Suehyun Lee, Ph.D†

* Dept. of Computer Engineering, College of IT Convergence, Gachon University, Seongnam, mbc94@gachon.ac.kr
†Dept. of Computer Engineering, College of IT Convergence, Gachon University, Republic of Korea

Abstract: This study compares Domain-Adaptive Pretraining (DAP) and From-Scratch Pretraining strategies for BERT models in Korean clinical NLP. We constructed a medical corpus of 499,432 documents and trained a domain-specific tokenizer using KCI medical journal abstracts, reducing tokenization output by 33.5% compared to a general-domain tokenizer. Two models were evaluated: BERT_Base, a DAP model with approximately 20 billion total training tokens, and BERT_Scratch, trained exclusively on the medical corpus with approximately 8.27 billion tokens. Despite 2.4 times fewer total tokens, BERT_Scratch outperformed BERT_Base on both KorMedQA and KBMC downstream tasks. These results demonstrate that From-Scratch Pretraining with a domain-specific tokenizer is an effective strategy for Korean clinical NLP, even with limited corpus size.

Keyword: *BERT, Domain-Adaptive Pretraining, From-Scratch Pretraining, Korean Clinical NLP, Tokenizer*

I. 배 경

BERT(Bidirectional Encoder Representations from Transformers)는 사전학습 언어모델로서 개체명 인식(Named Entity Recognition), 의미적 텍스트 유사도(Semantic Textual Similarity), 관계 추출(Relation Extraction) 등 다양한 의료 도메인 과제에서 널리 활용되어 왔다. 영어 도메인에서는 일반 도메인으로 사전학습된 BERT를 의료 말뭉치로 추가 학습하는 Domain-Adaptive Pretraining 기법이 BioBERT를 통해 제안되었으며[1], 처음부터 의료 도메인의 말뭉치로만 학습하는 From-Scratch Pretraining 기법이 PubMedBERT를 통해 시도된 바 있다.[2] 한국어 도메인에서는 KM-BERT가 Domain-Adaptive Pretraining 기법을 적용한 사례로 보고되었으나[3], 의료 도메인만의 말뭉치로 처음부터 사전학습한 모델은 아직 공개된 바 없다.

한국어는 교착어적 특성을 가지고 있어, 조사와 어미가 어근에 결합하여 하나의 어절을 이루므로 동일한 의미의 단어라도 문맥에 따라 다양한 표현형이 생성된다. 이로 인해 어휘의 다양성이 급격히 증가하며, 영어 대비 전반적인 모델의 성능이 낮게 나타나는 주요 요인으로 지적되어 왔다.[4] 이에 더하여 일반 도메인에 맞게 학습된 토크나이저는 희소한 의학 용어를 과도하게 분절하는 문제가 발생한다. 예를 들어, '심근경색 후 발생한 심막염에 methylprednisolone을 정맥 투여하였다.'라는 문장을 범용 토크나이저로 분절하면, '심근경색'은 ['심근', '##경', '##색']으로, 'methylprednisolone'은 ['me', '##th', '##yl', '##pr', '##ed', '##n', '##is', '##ol', '##one']과 같이 의미 단위가 파괴되어 과도하게 분리된다. 반면, 의료 도메인에서 학습된 토크나이저는 상대적으로 빈도가 높은 '심근경색'과 'methylprednisolone'을 각각의 토큰으로 인식한다. 이러한 토크나이저의 분절 방식 차이는 다운스트림 태스크의 성능에 직접적인 영향을 미칠 수 있다.

범용 토크나이저의 한계를 보완하기 위해 KM-BERT에서는 Domain-Adaptive Pretraining 수행 시 의학 용어를 어휘집에 추가하는 방법을 시도하였다. 그러나 일반 도메인에서 학습된 가중치 위에 새로운 어휘를 추가하는 것만으로는 도메인에 최적화되지 않은 초기화의 영향을 근본적으로 해소하기 어렵다.[2] 따라서 본 연구에서는 한국어 임상 데이터를 효과적으로 처리하기 위한 From-Scratch Pretraining 기반 BERT 모델을 구축하고, 이를 기존 Domain-Adaptive Pretraining 방식과 다운스트림 태스크에서 비교하여 From-Scratch Pretraining 방식의 유효성을 실증적으로 검증하는 것을 목표로 한다.

II. 방 법

본 연구에서는 Domain-Adaptive Pretraining 방식과 From-Scratch Pretraining 방식의 성능 차이를 검증하기 위해, 동일한 말뭉치로 두 모델을 사전학습한 후 다운스트림 태스크의 성능을 비교하였다.

1. 사전학습 말뭉치 및 토크나이저 구성

사전학습 말뭉치는 나무위키·위키피디아의 의학 관련 문서, AI-Hub의 의학지식 데이터, KCI 의학·약학 저널의 한국어 초록, MSD 매뉴얼, 국립국어원 신문

말뭉치의 건강·미용 섹션으로 구성하였다. 도메인 특화 토크나이저는 KCI 초록만으로 학습하였는데, 해당 초록에 임상 현장에서 실제로 사용되는 영문 약물명, 질환명 등의 전문 용어가 밀도 높게 포함되어 있어 한국어와 영문 의학 용어를 동시에 어휘에 반영할 수 있을 것으로 판단하였기 때문이다. 범용 토크나이저로는 한국어 일반 도메인으로 사전학습된 KLUE-BERT의 토크나이저를 사용하였다. 두 토크나이저의 어휘 크기는 32,000으로 동일하나, 공유하는 토큰은 12,223개에 불과하며 어휘 구성에 상당한 차이가 존재한다. 수집한 말뭉치의 출처별 구성은 Table 1과 같다.

Table 1. Composition of pretraining corpus

출처	문서 수	단어 수
위키피디아·나무위키	21,025	3,576,818
AI-Hub	14,163	8,115,949
KCI 초록	42,215	5,855,588
MSD	3,399	1,971,990
국립국어원 신문 말뭉치	376,415	110,839,624
합계	499,432	136,215,557

이 말뭉치를 각 토크나이저로 분절한 결과, KLUE-BERT의 범용 토크나이저는 약 4.14억 토큰을, 도메인 특화 토크나이저는 약 2.76억 토큰을 생성하였다. 이는 도메인 특화 토크나이저가 동일한 말뭉치를 약 33.5% 적은 토큰으로 분절하는 것을 의미하며, 배경에서 제시한 methylprednisolone 등의 전문 의학 용어를 과도하게 분절하지 않고 하나의 의미 단위로 처리한 결과이다.

2. 모델 구성 및 사전학습 전략

본 연구에서는 다음의 두 가지 모델을 구성하여 비교 실험을 수행하였다. BERT_Base는 일반 도메인 약 117억 토큰(23.4억 × 5 epoch)으로 사전학습된 모델을 초기 가중치로 사용한 뒤, 상기 말뭉치로 Domain-Adaptive Pretraining을 수행한 모델이다. BERT_Scratch는 일반 도메인 사전학습 없이 상기 말뭉치만으로 토크나이저와 모델 가중치를 모두 처음부터 학습한 모델로, 배경에서 언급한 임베딩 공간 불일치 문제로부터 자유롭다.

두 모델 모두 BERT-base 구조(12 layers, 768 hidden, 12 attention heads)를 기반으로 하며, Masked Language Modeling(MLM)과 Next Sentence Prediction(NSP) 과제를 통해 사전학습을 수행하였다. 수집된 의료 말뭉치의 크기가 현저히 작으므로, 두 모델이 동일한 양의 토큰에 노출되도록 하였다. 동일 말뭉치에서 생성되는 토큰 수가 상이하므로, BERT_Base는 20 epoch(약 82.9억 토큰), BERT_Scratch는 30 epoch(약 82.7억 토큰)으로 설정하여 노출되는 토큰 수를 약 82.8억 수준으로 통제하였다.

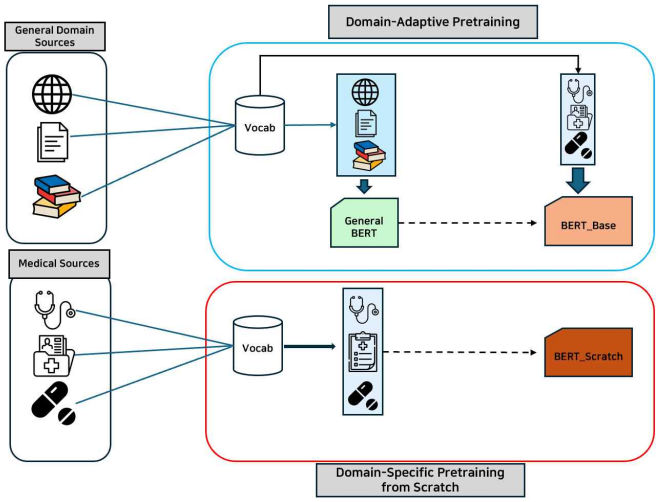


Figure 1. Comparison of Domain-Adaptive Pretraining (DAP) and From-Scratch Pretraining pipelines

3. 다운스트림 태스크 및 평가 방법

사전학습된 두 모델의 성능을 비교하기 위해, 다음의 두 가지 다운스트림 태스크에 대하여 파인튜닝을 수행하였다. KorMedQA는 의사, 간호사, 약사, 치과의사의 4개 직종별 국가시험 문항으로 구성된 5지선다형 객관식 의료 질의응답 과제로, 질문과 답변의 5개 쌍을 각각 인코더에 통과시킨 후 선형 분류층을 통해 하나의 정답을 결정하며, 각 직종별 정확도(Accuracy)와 전체 정확도로 평가하였다. KBMC는 임상 텍스트의 각 토큰을 질환(Disease), 신체 부위(Body), 치료(Treatment), 기타(O)의 네 범주로 분류하는 과제로, 임상 기록에서 의료 개체를 정확히 식별하는 능력을 각 분류별 F1 Score와 전체 F1 Score로 평가하였다.

Ⅲ. 결 과

두 모델 모두 동일한 하이퍼파라미터로 파인튜닝을 수행하였다. KorMedQA는 learning rate 5e-5, epoch 20으로, KBMC는 learning rate 1e-4, epoch 5로 설정하였으며, 두 태스크 모두 dropout 0.1, warmup ratio 0.1, weight decay 0.01, effective batch 64를 적용하였다. 각 태스크의 성능 비교에서 우수한 수치는 볼드 처리하였으며, 모든 수치는 소수점 셋째 자리에서 반올림하였다.

1. KorMedQA

	Doctor	Nurse	Pharm	Dentist	Total
BERT_Base	28.74	31.44	**23.50**	20.59	25.79
BERT_Scratch	**29.89**	**31.89**	**23.50**	**24.54**	**27.15**

Table 2. KorMedQA performance by medical profession (Accuracy, %)

Table 2에서 확인할 수 있듯이, BERT_Scratch는 Total 27.2%로 BERT_Base의 25.8% 대비 1.4%p 높은 성능을 보였다. 특히 Dentist 문항에서 3.9%p의 가장 큰 차이를 보였으며, Doctor 및 Nurse 문항에서도 소폭 우세하였다.

2. KBMC

	Disease	Body	Treatment	Macro F1
BERT_Base	**89.85**	81.18	74.18	81.74
BERT_Scratch	89.35	**82.58**	**76.15**	**82.69**

Table 3. KBMC named entity recognition performance (F1, %)

Table 3에서 확인할 수 있듯이, BERT_Scratch는 Macro F1 82.7%로 BERT_Base의 81.7% 대비 1.0%p 높은 성능을 보였다. 특히 Treatment 범주에서 2.0%p의 가장 큰 차이를 보였으며, Body 범주에서도 1.4%p 우세하였다. Disease 범주에서는 BERT_Base가 0.5%p 높았으나, 전반적으로 BERT_Scratch가 더 높은 성능을 기록하였다.

IV. 결 론

본 연구에서는 한국어 임상 데이터 처리를 위한 BERT 모델의 사전학습 전략을 비교하기 위하여 Domain-Adaptive Pretraining과 From-Scratch Pretraining 기반 모델을 구축하고, KorMedQA와 KBMC 두 가지 다운스트림 태스크를 통해 그 성능을 평가하였다.

실험 결과, BERT_Scratch는 의료 도메인 약 82.7억 토큰만으로 학습하였음에도 불구하고, 일반 도메인 사전학습을 포함하여 총 약 200억 토큰을 학습한 BERT_Base 대비 KorMedQA와 KBMC 모두에서 우수한 성능을 보였다. 이는 총 학습 토큰 수에서 약 2.4배 불리한 조건에서도 From-Scratch Pretraining 방식이 Domain-Adaptive Pretraining 방식을 상회할 수 있음을 실증적으로 보여주는 결과이다.

이러한 결과의 배경에는 도메인 특화 토크나이저의 역할이 크다. Domain-Adaptive Pretraining 모델의 경우 일반 도메인에서 학습된 임베딩 공간 위에 의료 말뭉치를 추가 학습하더라도 기존 가중치와의 불일치가 잔존하는 반면, From-Scratch Pretraining 모델에서는 토크나이저와 임베딩이 의료 도메인에 맞추어 동시에 최적화되므로, 동일한 말뭉치를 33.5% 적은 토큰으로 분절하면서도 의미 단위를 보존할 수 있었다. 특히 KBMC의 Treatment 범주에서 2.0%p의 성능 차이가 나타난 것은 토크나이저의 분절 품질이 개체 경계 인식에 직접적으로 기여함을 시사한다.

본 연구는 제한된 규모의 말뭉치 환경에서도 From-Scratch Pretraining 방식이 유효함을 보여주었다. 향후 K-MIMIC과 같은 대규모 한국어 임상 텍스트가 공개되면 From-Scratch Pretraining 모델의 성능이 더욱 향상될 것으로 기대되며, 본 연구가 한국어 의료 자연어처리 모델 구축에 있어 From-Scratch Pretraining의 필요성과 방향성을 제시하는 기초 연구로서 기여할 수 있기를 기대한다.

참고문헌

1. Lee J, Yoon W, Kim S, et al. "BioBERT: a pre-trained biomedical language representation model for biomedical text mining." Bioinformatics 36.4 (2020): 1234-1240.
2. Gu Y, Tinn R, Cheng H, et al. "Domain-specific language model pretraining for biomedical natural language processing." ACM Transactions on Computing for Healthcare 3.1 (2021): 1-23.
3. Kim Y, Kim JH, Lee JM, et al. "A pre-trained BERT for Korean medical natural language processing." Scientific Reports 12.1 (2022): 13847.
4. Lee S, Jang H, Baik Y, et al. "KR-BERT: A small-scale Korean-specific language model." Journal of KIISE 47.7 (2020): 682-692.
5. Johnson AEW, Pollard TJ, Shen L, et al. "MIMIC-III, a freely accessible critical care database." Scientific Data 3.1 (2016): 160035.